



Création et utilisation de la base de données

Portfolio Data & IA



Contexte du projet

Modélisation et création d'une base de données

- Analyse des données
- Diagramme des données
- Création de la base de donnée
- Insertion des données
- Requêtes SQL



La stratégie de sauvegarde et la conformité RGPD

- Suppression des données personnelles
- Sauvegarde sur une durée glissante de 5 ans

Les données initiales

donnees_commune.csv

	A	B	C	D	E	F	G	H	I	J	
1	CODREG	CODDEP	CODARR	CODCAN	CODCOM	COM	PMUN	PCAP	PTOT		
2	84	01	02	08	001	L'Abergement-Clémenciat	779	19	798		
3	84	01	01	01	002	L'Abergement-de-Varey	256	1	257		
4	84	01	01	01	004	Ambérieu-en-Bugey	14134	380	14514		
5	84	01	02	22	005	Ambérieux-en-Dombes	1751	25	1776		
6	84	01	01	04	006	Ambλέον	112	6	118		
7	84	01	01	01	007	Ambroinay	2800	115	2915		

fr-esr-referentiel-geographique.csv

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	
reg_n	reg_nom	reg_nom	aca_nom	dep_nom	com_cod	com_cod	com_cod	com_id	com_nom	com_nom	com_nom	uu_code	uu_id	uucr_id	uucr_nom	ze_id	dep_cod	dep_id	dep_nom	dep_num
Province	Auvergne-Rhône-Alpes	Rhône-Alpes	Lyon	Ain	01001	1001	1001	C01001	L'ABERGEM	L'ABERGEM	L'Abergement-Clémenciat	SO	CR01001	L'Abergement	ZE8213	1	D001	Ain (01)	01 - Ain	
Province	Auvergne-Rhône-Alpes	Rhône-Alpes	Lyon	Ain	01002	1002	1002	C01002	L'ABERGEM	L'ABERGEM	L'Abergement-de-Varey	SO	CR01002	L'Abergement	ZE8201	1	D001	Ain (01)	01 - Ain	
Province	Auvergne-Rhône-Alpes	Rhône-Alpes	Lyon	Ain	01003	1003	1003	C01003	AMAREINS	AMAREINS	Amareins	SO	SO	SO	Amareins	SO	1	D001	Ain (01)	01 - Ain


Valeurs-foncières.csv

Date mutation	Nature mutati	Valeur foncièr	No v	B/T	Code type de v	Type de v	Code v	Voie	Code ID commu	Code pos	Commune	Code departem	Code commu	Préfixe de secti	Secti	No pl	No Volum
2020/01/02	Vente	165000	347		0	RUE		20 DU CHATEAU	1	1170	CHEVRY	01	103		A	302	
2020/01/02	Vente	355680	4		15	BD		1000 EDOUARD BAUDOIN	205	6160	ANTIBES	06	004		CP	186	
2020/01/02	Vente	229500	20	B	0	RUE		3975 MARCEAU	142	6000	NICE	06	088		LS	169	


L'extrait du dictionnaire des données

	Nom des colonnes	Type de données	Valeur par défaut	Taille	Clé	Description
REGION	reg_code	VARCHAR	NOT NULL	3	Clé primaire	Code région (référentiel)
	reg_nom	VARCHAR	NOT NULL	100		Nom de la région
DEPARTEMENT	dep_code	VARCHAR	NOT NULL	3	Clé primaire	Code département (INSEE : 01, 2A, 971...)
	dep_nom	VARCHAR	NOT NULL	100		Nom du département
	reg_code	VARCHAR	NOT NULL	3	Clé étrangère	Référence Region.reg_code
COMMUNE	com_code	VARCHAR	NOT NULL	6	Clé primaire (partie 1)	Code commune (format importé)
	com_nom	VARCHAR	NOT NULL	100		Nom de la commune
	dep_code	VARCHAR	NOT NULL	3	Clé primaire (partie 2) / Clé étrangère	Référence Departement.dep_code
	population	INT	NOT NULL	11		Population de la commune (non historisée)
BIEN	id_bien	INT	NOT NULL AUTO_INCREMENT	11	Clé primaire	Identifiant technique du bien
	no_voie	VARCHAR	NOT NULL	5		Numéro de voie
	B_T_Q	VARCHAR	NOT NULL DEFAULT "	1	Clé étrangère (composite)	Index Bis/Ter/Quart
	type_de_voie	VARCHAR	NUL	10		Type de voie
	voie	VARCHAR	NUL	50	Clé étrangère (composite)	Nom de la voie
	com_code	VARCHAR	NOT NULL	6		Référence Commune.com_code
	com_dep	VARCHAR	NOT NULL	3	Clé étrangère (composite)	Référence Commune.dep_code
	surface_carrez_1er_lot	FLOAT	NOT NULL	5		Surface Carrez du 1er lot (0 décimale)
	surface_batie	FLOAT	NOT NULL	5	Index (BTREE)	Surface bâtie (0 décimale)
	prefixe_section	INT	NUL	11		Préfixe de section cadastrale
	section	VARCHAR	NOT NULL	5	Clé étrangère	Section cadastrale
	no_plan	INT	NOT NULL	11		Numéro de plan cadastral
	'1er_lot'	VARCHAR	NOT NULL	10	Clé étrangère	Identifiant du 1er lot (à quoter en SQL)
	hash_index	VARCHAR	NUL	150		Hash d'indexation/dédoublonnage MD5(CONCAT())
VENTE	id_vente	INT	NOT NULL AUTO_INCREMENT	11	Clé primaire	Identifiant technique de vente
	id_bien	INT	NOT NULL	11	Clé étrangère	Référence Bien.id_bien
	date_mutation	DATE	NOT NULL			Date mutation (YYYY-MM-DD)
	valeur_fonciere	FLOAT	NUL	20		Valeur foncière (prix)
	nature_mutation	VARCHAR	NUL	50		Nature de mutation
	nb_lots	INT	NUL	11		Nombre de lots

Le schéma relationnel normalisé



les tables créées et les données chargées



Les requêtes ou screenshot qui permettent de démontrer le bon chargement des données

```
select COUNT(*) from valeur_fonciere; -- 34169
select COUNT(*) from donnees_communes; -- 34991|
select COUNT(*) from referentiel_geographique; -- 38916
select COUNT(id_vente) from vente; -- 34169
select COUNT(id_bien) from bien; -- 34169
```



Requêtes SQL et résultats

Requête 1

Nombre total d'appartements vendus au 1er semestre 2020

```
select count(*) from vente inner join bien on vente.id_bien = bien.id_bien  
where type_local = "Appartement" and date_mut BETWEEN '2020-01-01' and '2020-06-30'
```

Résultat : 31378

Requête 2

Le nombre de ventes d'appartement par région pour le 1er semestre 2020.

```
select count(id_vente), region.reg_nom from vente
INNER JOIN bien on vente.id_bien = bien.id_bien
INNER JOIN departement on bien.com_dep = departement.dep_code
INNER JOIN region on region.reg_code = departement.reg_code
where type_local = "Appartement" and date_mutation BETWEEN '2020-01-01' and '2020-06-30'
GROUP BY departement.reg_code
ORDER BY count(id_vente) DESC
```

Résultat :

count(id_vente)	reg_nom
13995	Ile-de-France
3649	Provence-Alpes-Côte d'Azu
3253	Auvergne-Rhône-Alpes
1932	Nouvelle-Aquitaine
1640	Occitanie
1357	Pays de la Loire
1254	Hauts-de-France
984	Grand Est
983	Bretagne
862	Normandie
696	Centre-Val de Loire
376	Bourgogne-Franche-Comté
223	Corse
94	Martinique
44	La Réunion
34	Guyane
2	Guadeloupe

Requête 3

Proportion des ventes d'appartements par le nombre de pièces.

```
select concat(round(count(id_vente)/SUM(COUNT(*) OVER () * 100,2),'%') as proportion, bien.nb_piece from vente
INNER JOIN bien on vente.id_bien = bien.id_bien
where type_local = "Appartement"
GROUP BY bien.nb_piece
ORDER BY bien.nb_piece ASC
```

Résultat :

proportion	nb_piece
0.10%	0
21.48%	1
31.18%	2
28.57%	3
14.21%	4
3.55%	5
0.65%	6
0.17%	7
0.05%	8
0.03%	9
0.01%	10
0.00%	11

Requête 4

Liste des 10 départements où le prix du mètre carré est le plus élevé.

```
select departement.dep_code as "département", round(AVG(vente.valeur_fonciere/bien.surface_batie), 2) as 'prix moyen au m2' from vente
INNER JOIN bien on vente.id_bien = bien.id_bien
INNER JOIN departement on departement.dep_code = bien.com_dep
WHERE type_local = "Appartement"
group by departement.dep_code
ORDER BY round(SUM(vente.valeur_fonciere)/SUM(bien.surface_batie), 2) DESC limit 0,10;
```

Résultat :

département	prix moyen au m2
75	12124.73
92	7379.81
94	5457.64
06	4645.97
93	4376.3
78	4100.01
74	4108.85
69	4070.4
33	3850.87
2A	3805.56

Requête 5

Prix moyen du mètre carré d'une maison en Île-de-France.

```
select region.reg_nom as "région", round(AVG(vente.valeur_fonciere/bien.surface_batie), 2) as 'prix moyen au m2' from vente
INNER JOIN bien on vente.id_bien = bien.id_bien
INNER JOIN departement on departement.dep_code = bien.com_dep
INNER JOIN region on region.reg_code = departement.reg_code
WHERE type_local = "Maison" and region.reg_nom = "Île-de-France"
group by region.reg_code
ORDER BY round(AVG(vente.valeur_fonciere/bien.surface_batie), 2) DESC limit 0,10
```

Résultat :

région	prix moyen au m2
► Ile-de-France	3997.71

Requête 6

Liste des 10 appartements les plus chers avec la région et le nombre de mètres carrés.

```
select region.reg_nom as "région", vente.valeur_fonciere as "valeur", bien.surface_batie as "surface du batie" from vente
INNER JOIN bien on vente.id_bien = bien.id_bien
INNER JOIN departement on departement.dep_code = bien.com_dep
INNER JOIN region on region.reg_code = departement.reg_code
WHERE type_local = "Appartement"
ORDER BY vente.valeur_fonciere DESC limit 0,10
```

Résultat :

région	valeur	surface du batie
Ile-de-France	9000000	10
Ile-de-France	8600000	62
Ile-de-France	8577713	289
Ile-de-France	7620000	42
Ile-de-France	7600000	200
Ile-de-France	7535000	143
Ile-de-France	7420000	357
Ile-de-France	7200000	241
Ile-de-France	7050000	310
Ile-de-France	6600000	76

Requête 7

Taux d'évolution du nombre de ventes entre le premier et le second trimestre de 2020.

```
SELECT
  CONCAT(round((t2.cnt - t1.cnt) / NULLIF(t1.cnt, 0) * 100.0, 2), '%') AS `taux entre T1 et T2`
FROM
  (SELECT COUNT(*) AS cnt
   FROM vente
   WHERE date_mutation BETWEEN '2020-01-01' AND '2020-03-31') AS t1
CROSS JOIN
  (SELECT COUNT(*) AS cnt
   FROM vente
   WHERE date_mutation BETWEEN '2020-04-01' AND '2020-06-30') AS t2;
```

Résultat :

taux entre T1 et T2
▶ 3.68%

Requête 8

Le classement des régions par rapport au prix au mètre carré des appartements de plus de 4 pièces.

```
select region.reg_nom as "région", round(AVG(vente.valeur_fonciere/bien.surface_batie), 2) as 'prix moyen au m2' from vente
INNER JOIN bien on vente.id_bien = bien.id_bien
INNER JOIN departement on departement.dep_code = bien.com_dep
INNER JOIN region on region.reg_code = departement.reg_code
WHERE bien.nb_piece > 4 and bien.type_local = 'Appartement'
group by region.reg_code
ORDER BY round(AVG(vente.valeur_fonciere/bien.surface_batie), 2) desc;
```

Résultat :

région	prix moyen au m2
Ile-de-France	8015.09
La Réunion	3659.83
Corse	3046.47
Provence-Alpes-C	3005.24
Auvergne-Rhône-	2768.87
Nouvelle-Aquitain	2510.18
Bretagne	2271.86
Hauts-de-France	2203.61
Pays de la Loire	2186.72
Occitanie	2096.42
Normandie	1994.25
Centre-Val de Loir	1428.51
Grand Est	1313.26
Bourgogne-Francl	1068.93
Martinique	564.22

Requête 9

Liste des communes ayant eu au moins 50 ventes au 1er trimestre

```
select commune.com_nom as 'commune', count(id_vente) as 'nombre de vente' from vente
INNER JOIN bien on vente.id_bien = bien.id_bien
INNER JOIN commune on bien.com_code = commune.com_code and bien.com_dep = commune.dep_code
WHERE vente.date_mutation BETWEEN '2020-01-01' and '2020-03-31' group by commune.com_nom HAVING count(id_vente) >= 50
ORDER BY count(id_vente) ASC
```

Résultat :

commune	nombre de vente
Issy-les-Moulineaux	50
Puteaux	53
Versailles	54
Ajaccio	54
Saint-Maur-des-Fossés	56
Toulon	59
Levallois-Perret	59
Paris 4e Arrondissement	60
Paris 2e Arrondissement	61
Rennes	61
Paris 8e Arrondissement	62
Sète	62
La Ciotat	62
Nîmes	63
Angers	64
Montreuil	65
Marseille 9e Arrondissement	66
Lille	67
Rueil-Malmaison	68
Vincennes	68
Marseille 1er Arrondissement	71
Marseille 4e Arrondissement	72
Antibes	77
Toulouse	78
Paris 3e Arrondissement	79
Paris 5e Arrondissement	79
Courbevoie	80
Marseille 8e Arrondissement	81
Asnières-sur-Seine	81
Paris 6e Arrondissement	86
Paris 7e Arrondissement	87
Paris 13e Arrondissement	94
Boulogne-Billancourt	99
Paris 9e Arrondissement	106
Grenoble	106
Paris 10e Arrondissement	109
Paris 12e Arrondissement	110
Paris 19e Arrondissement	116
Nantes	119
Paris 20e Arrondissement	127
Paris 14e Arrondissement	146
Bordeaux	157
Paris 16e Arrondissement	165
Paris 11e Arrondissement	169
Nice	173
Paris 18e Arrondissement	209
Paris 15e Arrondissement	215
Paris 17e Arrondissement	228

Requête 10

Différence en pourcentage du prix au mètre carré entre un appartement de 2 pièces et un appartement de 3 pièces.

```
SELECT
  CONCAT(round((t2.cnt - t1.cnt) / NULLIF(t1.cnt, 0) * 100.0, 2), '%') AS `Pourcentage de différence entre un appartement 2 et 3 pièces`
FROM
  (SELECT SUM(vente.valeur_fonciere)/SUM(bien.surface_batie) AS cnt
   FROM vente
   INNER JOIN bien on bien.id_bien = vente.id_bien
   WHERE bien.nb_piece = 2 and bien.type_local = 'Appartement') AS t1
CROSS JOIN
  (SELECT SUM(vente.valeur_fonciere)/SUM(bien.surface_batie) AS cnt
   FROM vente
   INNER JOIN bien on bien.id_bien = vente.id_bien
   WHERE bien.nb_piece = 3 and bien.type_local = 'Appartement') AS t2;
```

Résultat :

Pourcentage de différence entre un appartement 2 et 3 pièces
▶ -11.23%

Requête 11

Les moyennes de valeurs foncières pour le top 3 des communes des départements 6, 13, 33, 59 et 69.

```
WITH base AS (
    SELECT
        d.dep_code,
        d.dep_nom AS departement,
        c.com_nom AS commune,
        ROUND(SUM(v.valeur_fonciere) / COUNT(v.id_bien), 2) AS moyenne
    FROM bien b
    JOIN vente v ON v.id_bien = b.id_bien
    JOIN commune c ON c.com_code = b.com_code AND c.dep_code = b.com_dep
    JOIN departement d ON d.dep_code = c.dep_code
    WHERE c.dep_code IN ('06','13','33','59','69')
    GROUP BY d.dep_code, d.dep_nom, c.com_nom
),
ranked AS (
    SELECT
        ROW_NUMBER() OVER (PARTITION BY dep_code ORDER BY moyenne DESC) AS top3,
        departement,
        commune,
        moyenne
    FROM base
)
SELECT top3, departement, commune, moyenne
FROM ranked
WHERE top3 <= 3
ORDER BY departement, top3;
```

Résultat :

top3	departement	commune	moyenne
1	Alpes-Maritimes	Saint-Jean-Cap-Ferrat	968750
2	Alpes-Maritimes	Eze	655000
3	Alpes-Maritimes	Mouans-Sartoux	476898.12
1	Bouches-du-Rhône	Gignac-la-Nerthe	330000
2	Bouches-du-Rhône	Saint-Savournin	314425
3	Bouches-du-Rhône	Cassis	313416.88
1	Gironde	Lège-Cap-Ferret	549500.64
2	Gironde	Vayres	335000
3	Gironde	Arcachon	307435.93
1	Nord	Bersée	433202
2	Nord	Cysoing	408550
3	Nord	Halluin	322250
1	Rhône	Ville-sur-Jarnioux	485300
2	Rhône	Lyon 2e Arrondissement	455217.26
3	Rhône	Lyon 6e Arrondissement	426968.25

Requête 12

Les 20 communes avec le plus de transactions pour 1000 habitants pour les communes qui dépassent les 10 000 habitants.

```
SELECT commune.com_nom as 'commune', count(vente.id_bien) as 'nombre de vente', round(((count(vente.id_bien)/commune.population)*1000), 2) as 'moyenne de vente pour 1000 habitants' from bien
inner join vente on vente.id_bien = bien.id_bien
inner join commune on commune.com_code = bien.com_code and commune.dep_code = bien.com_dep
where commune.population > 10000
group by commune.com_nom, commune.population
order by round(((count(vente.id_bien)/commune.population)*1000), 2) desc limit 0,20
```

Résultat :

commune	nombre de vente	moyenne de vente pour 1000 habitants
► Paris 2e Arrondissement	127	5.84
Paris 1er Arrondissement	79	4.92
Paris 3e Arrondissement	161	4.69
Arcachon	55	4.62
La Baule-Escoublac	77	4.58
Paris 4e Arrondissement	120	4.08
Roquebrune-Cap-Martin	52	3.99
Paris 8e Arrondissement	139	3.83
Sanary-sur-Mer	60	3.50
La Londe-les-Maures	37	3.43
Paris 9e Arrondissement	208	3.43
Paris 6e Arrondissement	139	3.38
Saint-Cyr-sur-Mer	38	3.24
Chantilly	35	3.13
Pornichet	35	3.06
Saint-Mandé	69	3.06
Paris 10e Arrondissement	264	3.04
Menton	91	2.94
Saint-Hilaire-de-Riez	33	2.87
Vincennes	141	2.81



Merci !