


Rapprochement et analyse des données de ventes



Portfolio IA
Data analyst (greta)
10 avril 2026

Analyses Exploratoires des Données



Aucune donnée personnelle n'est présente dans les datasets, il n'y a donc pas d'enjeu RGPD dans ce projet.

Principales anomalies détectées

Incohérences :

Homogénéité code SKU

Id dans liaison

Valeurs manquantes

Problèmes de valeurs :

Prix négatif

Prix négatif et en stock

Prix vente < prix achat

Taux de marge négatif


Principales anomalies détectées

Journal des erreurs

ID	Source	Champ concerné	Problème constaté	Impact	Action recommandée	Explication de l'action
E-01	ERP	stock_quantity	Valeurs négatives détectées (-10, -1)	Biais dans le calcul du stock, de la rotation et des marges	Bloquer la saisie de valeurs négatives dans l'ERP	Mettre en place une règle système empêchant l'enregistrement d'une quantité < 0.
E-02	ERP	stock_status	Statut stock incohérent avec la quantité (ex : quantité > 0 mais "outofstock")	Mauvaise interprétation de la disponibilité produit et indicateurs stock faussés	Reparamétrer la règle de calcul du statut stock	Automatiser le statut selon la quantité réelle.
E-03	ERP	price	Prix négatifs détectés sur certains produits	Chiffre d'affaires et marges complètement faussés	Bloquer immédiatement l'enregistrement de prix ≤ 0	Un prix négatif ne doit jamais être possible dans le système.
E-04	ERP	price / stock	Produit avec prix négatif mais stock disponible	Risque de vente avec un prix erroné	Bloquer la mise en vente tant que le prix n'est pas valide	Empêcher toute transaction avec un prix incorrect.
E-05	ERP	price / purchase_price	Absence d'information sur la devise	Risque d'erreur dans les analyses financières	Ajouter une colonne "currency"	Permet de sécuriser les analyses financières et conversions.
E-06	Web	sku	Codification des SKU non homogène	Risque d'échec de jointure avec l'ERP	Formaliser une règle de codification	Garantir la cohérence des identifiants produits.
E-07	ERP	price / purchase_price	Taux de marge négatif détecté	Risque de vente à perte ou erreur de prix	Mettre une alerte automatique si prix de vente < prix d'achat	Identifier immédiatement les ventes potentiellement déficitaires.
E-08	ERP / Web	product_id / sku	Références présentes dans un dataset mais absentes dans l'autre	Produits exclus des analyses	Vérifier et maintenir la table de liaison	Garantir l'intégrité des rapprochements ERP/Web.

Aucune donnée personnelle n'est présente dans les datasets, il n'y a donc pas d'enjeu RGPD dans ce projet.

Fusion ou consolidations des données



Choix des attributs	product_id, sku, prix, prix d'achat, quantités vendues, stock, description produit
Clés utilisées	product_id (ERP), sku (Web), table de liaison (product_id ↔ id_web)
Vigilances particulières	vérification de la cohérence des identifiants, harmonisation du type des clés, contrôle des valeurs manquantes, suppression des doublons sur sku, vérification des correspondances ERP/Web
Difficultés rencontrées	correspondances manquantes entre ERP et Web, références présentes dans un dataset mais absentes dans l'autre, valeurs manquantes dans la table de liaison, anomalies de codification des SKU, risque de jointures incorrectes

Analyses univariées du prix

Méthode

méthode IQR (écart interquartile)

Z-scores ($> |3|$) pour identifier les anomalies de prix

Objectif

Comprendre la distribution des prix

(répartition des prix, tendance centrale, détection des outliers)

Visualisation


Boxplot (détection IQR des valeurs extrêmes)

Graphiques en barres (tops 20)

Heatmap & tableau (corrélations)

Analyses univariées du prix

Distribution des prix des bouteilles Les valeurs atypiques sont identifiées à l'aide de la méthode de l'écart interquartile (IQR).



Médiane ≈ 23 €

La majorité des prix se situe **entre 14 € et 42 €**

Quelques vins premium atteignent **plus de 200 €**

► Le catalogue est majoritairement composé de vins de gamme intermédiaire, avec quelques références premium présentant des prix nettement plus élevés. *Analyse réalisée sur les ventes du mois d'octobre.*

Méthodes et Statistiques



Statistiques descriptives

- CA
- quantités vendues
- stocks
- taux de marge




Analyse de relations entre variables

- corrélations
(prix, ventes, stocks)

Outils de visualisations : diagrammes en barres et heatmap de corrélation


Analyse du chiffre d'affaires du site web

Top 20 des articles en chiffre d'affaires




Analyse du chiffre d'affaires du site web

Top 20 des articles en quantités vendues




Analyse du chiffre d'affaires du site web

Top 20 des produits avec le plus de mois de stock




Analyse du taux de marge

Taux de marge moyen par type de produit



Le taux de marge varie selon les catégories. Les spiritueux comme le Cognac ou le Whisky présentent des marges plus élevées, ce qui peut orienter les décisions commerciales.

Analyse des corrélations entre prix, ventes et stocks



Conclusion des analyses

- Volumes de ventes élevés sur des vins plus accessibles
- Certaines références présentent une rotation lente des stocks : potentiel d'optimisation.
- Niveaux de marge variables selon les catégories : opportunités d'ajustement de la stratégie commerciale.

Pistes d'amélioration : suivi des produits stratégiques, optimisation des stocks et mise en place d'indicateurs de performance.

Création du Bottleneck Dataset Final

Le dataset final est obtenu après les étapes suivantes :

- nettoyage des données
- correction des anomalies
- fusion des données ERP, Web et de la table de liaison
- création de nouvelles variables analytiques

Variables créées pour l'analyse :

- CA par produit
- part du CA
- cumul du CA

Ce dataset consolidé constitue la base unique utilisée pour l'ensemble des analyses présentées.

Actions pour la suite

Amélioration du pilotage business

Valoriser les produits premium

Les vins à prix élevé génèrent une forte valeur par vente.

- ⇒ renforcer leur visibilité sur le site
- ⇒ les mettre en avant dans les recommandations ou promotions

Sécuriser le cœur du catalogue

Les vins autour de 35 € génèrent la majorité du chiffre d'affaires.

- ⇒ surveiller les stocks pour éviter les ruptures
- ⇒ suivre leur performance commerciale

Optimiser la longue traîne

Certaines références se vendent peu et restent longtemps en stock.

- ⇒ identifier les produits à rotation lente
- ⇒ ajuster les prix ou la visibilité
- ⇒ réduire les volumes d'achat si nécessaire

Actions pour la suite

Amélioration de la gestion des données

Structurer les données pour faciliter les analyses

Un nouveau fichier XLSX structuré et nettoyé a été créé afin de :

- ⇒ centraliser les données produits
- ⇒ faciliter les analyses futures

Standardiser la saisie des données

Le nouveau format permet :

- ⇒ d'éviter les incohérences de données
- ⇒ d'assurer un suivi plus fiable des ventes et des stocks

Mettre en place un suivi régulier

Le fichier peut servir de base pour suivre :

- ⇒ chiffre d'affaires par produit
- ⇒ rotation des stocks
- ⇒ performance du catalogue

Point sur les compétences apprises

Ce qui s'est bien passé

Le nettoyage des données s'est globalement bien déroulé grâce à la trame méthodologique fournie, qui permet de suivre les étapes de façon structurée.

Ce qui a été le plus difficile

Prendre la décision de supprimer certaines données pour obtenir un jeu de données propre et exploitable.

Axes de progression

Tenter d'avantage de test statistiques notamment le principe de pareto (loi de pareto).